



DIRECTION GÉNÉRALE DES ENTREPRISES

Présentation générale

Ce que fait l'outil, comment l'installer, ce qu'il garantit

MARI(a)SOL — Mapping d'Alignement Réglementaire par Intelligence Albert pour le Suivi des Orientations Législatives

Version 1.5.3 du 9 septembre 2026

Document établi le 02/10/2026

Mapping d'Alignement Réglementaire par Intelligence Albert pour le Suivi des Orientations Législatives — Direction générale des entreprises.

Outil interne DGE de **négociation européenne** et de **cartographie des régimes d'accès aux données**.

L'application ne connaît que les documents que vous y chargez. Elle ne complète jamais avec des connaissances extérieures : si le corpus ne permet pas de répondre, elle le dit.

Les guides de ce dossier existent aussi **en PDF**, dans `documentation/` : présentation, installation, test d'usage, cadrage, architecture du code, déploiement, recette, journal des versions. Commencez par `0. Lisez-moi d'abord.pdf`, qui dit qui lit quoi.

Pour les régénérer après avoir modifié un fichier Markdown :

```
pip install -r requirements-dev.txt
python tools/build_docs.py
```

Démarrage

```
python -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt
cp .env.example .env          # y renseigner ALBERT_API_KEY
streamlit run app.py
```

Sans clé API, l'import, l'indexation, la recherche plein texte, la comparaison de versions et tous les calculs de coalition restent pleinement fonctionnels. Seules la rédaction des synthèses et la qualification fine des positions demandent un modèle.

Premier parcours

1. **Administration › Modèle** — tester la connexion, relever l'identifiant exact du modèle exposé et le reporter dans `.env`.
2. **Bibliothèque** — charger les documents. Le type est détecté, corrigible.
3. Puis l'outil qui correspond au besoin.

Les huit outils

Page	Ce qu'elle fait
Mode d'emploi	Par où commencer, les outils un par un, ce qui est garanti et ce qui ne l'est pas, questions fréquentes.
Bibliothèque	Import et gestion du corpus, récupération directe des textes publics depuis EUR-Lex. Découpage déterministe, indexation immédiate.
Recherche	« Qui a dit quoi sur tel sujet ? » Réponse rédigée dont chaque affirmation cite un passage vérifié, et répartition des occurrences par État membre.

Page	Ce qu'elle fait
Positions des États membres	Matrice d'alignement article par article avec la position française, classement des alliés, articles clivants — et les livrables Word et Excel.
Coalitions	Qui aller chercher pour ouvrir la négociation, blocs indépendants de la France, majorité qualifiée, minorités de blocage.
Suivi des amendements	Chaque demande écrite confrontée au texte publié : reprise, reprise partiellement, écartée — et le taux de reprise par délégation.
Comparaison de versions	Deux versions d'un texte, article par article : ce qui a changé mot à mot, la portée du changement, et trois cartes cliquables pour savoir par où commencer.
Régimes d'accès	Une situation d'entreprise, ce que disent les textes chargés disposition par disposition, et une fiche d'orientation Word.

Types de documents

Type	Découpage	Attribution
Commentaires consolidés (WK, tableau à 2 ou 3 colonnes)	par article, puis par État membre	code pays lu dans le tableau
Texte réglementaire (proposition, compromis, règlement)	par article, préambule à part	aucune
Texte libre (non-paper, note de position, compte rendu)	par paragraphe, courts regroupés	auteur deviné depuis l'en-tête, corrigeable

PDF et Word, plus la récupération HTML depuis EUR-Lex. Le découpage ne coupe jamais au milieu d'un paragraphe : un extrait cité doit pouvoir être retrouvé tel quel dans le document source.

Le type détecté à l'import est **corrigeable après coup** depuis l'onglet Corpus : il conditionne les pages où le document apparaît, et la détection se trompe régulièrement sur les textes consolidés.

EUR-Lex : HTML, pas PDF. Le PDF du Journal officiel est une mise en page — deux colonnes, césures, en-têtes insérés dans le texte. Son extraction introduit des écarts qui se comptent ensuite comme des modifications dans une comparaison de versions : on compare alors deux extractions, pas deux textes. Le HTML porte la structure des articles et donne un texte stable d'une version à l'autre. En contrepartie, la pagination du JO est perdue — les numéros de page des citations sont des repères internes, et le document importé le dit.

Le parser WK est validé sur les deux documents CSA2 de juillet 2026 : 1 278 contributions extraites, articles 3-70 et 71-97, 21 États membres.

Ce qui est déterministe, ce qui ne l'est pas

Étape	Nature	Composant
Découpage des documents	déterministe	pdfplumber , python-docx , expressions régulières
Index et recherche	déterministe	SQLite FTS5, local
Comparaison de versions	déterministe	diffliib , mot à mot
Scores, matrices, coalitions, majorité qualifiée	déterministe	pandas , networkx
Synthèse d'une réponse	modèle contraint	schéma Pydantic, chaque affirmation citée et vérifiée
Qualification d'une position ou d'un changement	modèle contraint	schéma Pydantic, citation vérifiée dans la source

Trois garde-fous, tous exécutés par le programme et non demandés au modèle :

- **Validation de schéma** — toute sortie non conforme est réinjectée avec l'erreur de validation, puis rejetée après épuisement des essais.
- **Vérification de citation** — une affirmation dont la citation ne se retrouve pas dans le texte source **n'est pas affichée**. L'interface indique combien d'affirmations ont été retirées.
- **Journal d'audit** — horodatage, modèle, empreinte SHA-256 du prompt, latence, conformité. Le contenu des prompts n'est jamais stocké.

Pourquoi pas d'embeddings

La recherche repose sur un index plein texte local (SQLite FTS5), pas sur une base vectorielle. Trois raisons : aucun texte ne sort pour être vectorisé — ce qui compte sur des documents LIMITE ; un résultat lexical s'explique, on voit quel terme l'a fait remonter ; et sur un corpus juridique, les recherches portent souvent sur des termes exacts (« cyber posture », « art. 100 », « scrutiny reservation »), cas où le lexical vaut le vectoriel.

Règles métier notables

Le silence français vaut accord. Sur un article que la France n'a pas amendé, la référence est le maintien du texte initial en l'état. Un État membre qui en demande la suppression ou la réécriture s'en écarte ; celui qui l'accepte s'y aligne. Cette règle est ce qui permet de renseigner la matrice sur l'ensemble des articles, et pas seulement sur ceux où la France s'est exprimée par écrit. Elle est surchargeable article par article.

Position la plus défavorable retenue. Quand un État s'exprime plusieurs fois sur le même article, c'est sa position la plus éloignée qui compte : une objection ne s'annule pas par un commentaire de soutien ailleurs.

Un silence n'est pas un accord entre deux États. Le taux d'accord d'une paire ne se calcule que sur les articles où les deux se sont exprimés.

Structure

app.py	point d'entrée : déclare la navigation
accueil.py	page d'accueil
pages/	les huit outils, un fichier par page
assets/	marque et logo de l'application
core/	
config.py	configuration par variables d'environnement
schemas.py	contrats Pydantic imposés au modèle
llm.py	client LLM sous contrainte + journal d'audit
ingest.py	ingestion universelle (3 familles de documents)
wk_parser.py	extraction des tableaux WK du Conseil
retrieval.py	index et recherche plein texte
qa.py	réponse sourcée, avec vérification des citations
scoring.py	qualification des positions, agrégations
coalition.py	blocs, majorité qualifiée, minorités de blocage
diff.py	comparaison de versions
eurlex.py	récupération des textes publics (HTML, sans dépendance)
labels.py	intitulés précis : disposition visée, aperçu
titres.py	regroupement des articles par titre du règlement
ponderation.py	pondération optionnelle d'un critère métier
fiabilite.py	points d'attention, à l'écran seulement
amendements.py	« nos amendements ont-ils été retenus ? »
nonpaper.py	positions extraites d'un non-paper, à valider
aide.py	base de connaissance et assistant de l'outil
duree.py	estimation et affichage des durées
palette.py	les deux conventions de couleur, source unique
ui.py	explication en haut, méthode en bas
store.py	persistance SQLite
viz.py	restitutions Plotly interactives
report.py	figures PNG et documents Word
excel.py	classeur Excel : graphiques natifs et texte de détail
modificatif.py	lecture d'un omnibus : instructions, reconstitution,
synthèse	
documentation/	les guides en PDF, produits par tools/build_docs.py
tools/build_docs.py	fabrique les PDF à partir des .md (dépendance de
développement)	
data/	
reference/populations.csv	populations pour le calcul de majorité qualifiée
corpus/	documents importés
regwatch.sqlite3	base locale
attic/	code non branché – voir attic/README.md

Points d'attention avant mise en service

- **Populations** : data/reference/populations.csv porte des chiffres approchés. Les valeurs officielles sont fixées chaque année par décision du Conseil modifiant son règlement

intérieur ; remplacez-les avant tout usage en négociation. L'écran Administration permet de les éditer.

- **Les positions écrites ne sont pas des votes.** Le calcul de majorité qualifiée dit ce que donnerait cette répartition si elle se transposait en vote — pas ce qui se passera.
- **Qualité de qualification** : à mesurer contre les matrices CSA2 faites à la main avant tout usage en note. C'est la seule vérité terrain disponible.

Configuration

Variable	Défaut	Rôle
REGWATCH_LLM_PROVIDER	albert	albert openai_compatible offline
ALBERT_BASE_URL	https:// albert.api.etalab.gouv.fr/v1	endpoint compatible OpenAI
ALBERT_API_KEY	—	jeton d'authentification
REGWATCH_LLM_MODEL	—	identifiant exact du modèle exposé
REGWATCH_LLM_TEMPERATURE	0.0	à laisser à zéro
REGWATCH_DB	data/regwatch.sqlite3	base locale
REGWATCH_AUDIT	1	journal des appels au modèle

L'API Albert suit les conventions de l'API OpenAI : le même client sert pour un LLM interne ou un modèle exécuté en local.