



DIRECTION GÉNÉRALE DES ENTREPRISES

Note de cadrage

Ce que l'outil est, pour qui, et ce qu'il n'est pas

MARI(a)SOL — Mapping d'Alignement Réglementaire par Intelligence Albert pour le Suivi des Orientations Législatives

Version 1.5.3 du 9 septembre 2026

Document établi le 02/10/2026

11 août 2026 · Direction de projets « économie de la donnée », DGE Remplace la v2 du même jour. Fait suite à la fiche méthodologique « Appli Streamlit — cartographie accès données ».

1. Ce que l'outil est devenu

Un **outil de négociation européenne** pour les agents de la direction, et un **outil d'orientation des entreprises** sur les régimes d'accès aux données. Deux publics, un socle technique commun : une bibliothèque de documents et un index, sur lesquels six outils travaillent.

L'application ne connaît que les documents qu'on y charge. C'est la propriété structurante : elle ne complète jamais avec des connaissances extérieures et, quand le corpus ne permet pas de répondre, elle le dit.

Outil	Ce qu'il fait gagner
Bibliothèque	Charger n'importe quel document de négociation : WK du Conseil, texte de compromis, non-paper, compte rendu.
Recherche	« Qui a dit quoi sur tel sujet, dans tout le corpus ? » avec citation et page.
Positions des États membres	La matrice d'alignement CSA2, produite automatiquement au lieu d'être faite à la main.
Coalitions	Qui pense comme qui, indépendamment de la France ; majorité qualifiée et minorités de blocage.
Comparaison de versions	Deux versions d'un texte, article par article, mot à mot — le suivi des omnibus.
Régimes d'accès	Une situation d'entreprise, et ce que disent les textes chargés.

2. Trois décisions d'architecture, et ce qu'elles coûtent

2.1 Le graphe de règles est abandonné

Décision. Le module « régimes d'accès » ne repose plus sur un graphe de règles écrit à la main, mais sur une réponse sourcée à partir des textes chargés dans l'application.

Pourquoi. Le graphe suppose qu'un juriste écrive et valide chaque règle. Cette ressource n'est pas disponible. Un graphe non validé produit des réponses fausses avec l'apparence de la rigueur — c'est pire qu'une réponse sourcée dont on voit la source.

Ce que ça coûte, et il faut le dire clairement. L'argument central du pitch DINUM était le déterminisme : « le droit est restitué de façon strictement déterministe », « pas de risque d'hallucination ». Cet argument-là ne tient plus sous cette forme. Deux exécutions sur la même question peuvent formuler la réponse différemment.

Ce qui le remplace, et qui est défendable. La garantie n'est plus le déterminisme mais la **vérifiabilité imposée par le programme** :

aucune affirmation n'est affichée sans une citation littérale, rattachée à un segment précis d'un document chargé, et vérifiée par le code contre le texte de ce segment. Une affirmation dont la citation est introuvable n'est pas signalée : elle est **retirée** avant affichage, et l'interface indique combien d'affirmations ont été écartées.

Ce n'est pas une consigne donnée au modèle — c'est un contrôle exécuté après lui, testé, et que le modèle ne peut pas contourner. La formulation à retenir pour la DINUM : *le modèle ne peut pas produire une assertion juridique qui ne soit pas adossée à un passage réellement présent dans un document de la direction.*

Le moteur de graphe reste dans le dépôt, sous `attic/`, avec ses 14 régimes et ses tests. Le jour où du temps de juriste est dégagé — même sur un périmètre restreint, par exemple les seuls régimes du Data Act — il se rebranche comme page sans réécriture.

2.2 Pas d'embeddings, un index plein texte local

La recherche repose sur SQLite FTS5, pas sur une base vectorielle. Trois raisons : aucun texte ne sort pour être vectorisé, ce qui compte sur des documents LIMITE ; un résultat lexical s'explique, on voit quel terme l'a fait remonter ; et sur un corpus juridique les recherches portent souvent sur des termes exacts — « cyber posture », « art. 100 », « scrutiny reservation » — cas où le lexical vaut le vectoriel.

Le point d'extension existe si le besoin apparaît : la fonction de reclassement est isolée et peut appeler un service de rerank sans toucher au reste.

2.3 Le silence français vaut accord

Votre remarque, et elle change la portée de l'outil. Sur un article que la France n'a pas amendé, la référence est le maintien du texte initial en l'état. Un État membre qui en demande la suppression ou la réécriture s'en écarte ; celui qui l'accepte s'y aligne.

Effet mesuré sur le CSA2 Titre III : la matrice passe de **10 articles renseignés à 28**. Auparavant l'outil ne calculait rien là où la France n'écrivait pas — c'était honnête mais inutilisable. La règle est surchargeable article par article depuis l'interface.

3. Ce qui est livré

- Application Streamlit à sept pages, organisée par outil. Zéro exception sur l'ensemble des écrans, corpus vide comme corpus chargé.
- **Ingestion universelle** : PDF et Word, trois familles de documents détectées automatiquement et corrigibles à l'import.
- **Parser WK validé** sur les deux documents CSA2 de juillet 2026 : 1 278 contributions, articles 3-70 et 71-97, 21 États membres.
- **Index et recherche plein texte** sur l'ensemble du corpus, tous types confondus.
- **Réponse sourcée** avec retrait effectif des affirmations non vérifiables.

- **Comparaison de versions** article par article, diff mot à mot, avec qualification de l'impact.
- **Coalitions** : taux d'accord entre toutes les paires, détection de blocs, majorité qualifiée, minorités de blocage, États pivots.
- **14 tests automatiques** sur les garde-fous — ils ont trouvé deux failles réelles pendant le développement : une citation d'un seul mot passait la vérification, et « should be deleted » n'était pas reconnu comme une demande de suppression. Les deux sont corrigées.

4. Ce qui reste

Charger les textes de référence. Le module « régimes d'accès » ne répond que sur ce qui est chargé. Il faut y mettre le RGPD, le Data Governance Act, le Data Act, la directive Open Data et l'AI Act — en version consolidée, en PDF ou Word, depuis EUR-Lex. Sans cela la page reste vide, et c'est voulu.

Brancher la clé Albert et relever l'identifiant exact du modèle exposé, depuis l'écran Administration.

Mesurer la qualité de qualification contre les matrices CSA2 faites à la main. C'est la seule vérité terrain disponible et elle est déjà là. Objectif : savoir sur quels types d'articles le classement automatique diverge, et de combien. À faire avant tout usage en note.

Remplacer les chiffres de population par ceux de l'annexe en vigueur du règlement intérieur du Conseil. Ceux livrés sont approchés ; l'écran Administration permet de les éditer sans toucher au code.

5. Risques

Risque	Portée	Traitement
Qualité de qualification du LLM inconnue	Une lecture diplomatique faussée	Comparaison chiffrée aux matrices manuelles, à faire avant tout usage
Réponse sourcée mais incomplète	Le corpus ne contient pas la disposition pertinente	La page liste ce que le corpus ne permet pas d'établir, plutôt que de combler
Chiffres de population approchés	Calcul de blocage faux	Avertissement affiché, fichier éditable, source documentée
Confusion positions écrites / votes	Conclusion politique erronée	Avertissement permanent sur la page Coalitions
Format WK non stable	Import cassé sur un futur document	Bascule automatique sur un autre découpage, avec avertissement — jamais d'extraction silencieusement partielle

Risque	Portée	Traitement
Documents LIMITE transmis à Albert	Conformité	Décision prise : Albert sur tout. Le mode <code>offline</code> reste disponible ; l'import, l'index, la recherche et le diff n'appellent jamais le réseau

6. Question ouverte

Faut-il rouvrir le graphe de règles sur un périmètre restreint ? Modéliser à la main les seuls régimes du Data Act représente peut-être deux jours de travail juridique. En échange, le module « régimes d'accès » redeviendrait déterministe sur le texte qui concentre l'essentiel des sollicitations d'entreprises, et l'argument tenu à la DINUM redeviendrait exact. Le code est prêt et testé. C'est un arbitrage de disponibilité, pas de technique.